

Université de Dschang

Master (M1) en Data Science et Ingénierie Mathématique

**MATHÉMATIQUE POUR L'APPRENTISSAGE
AUTOMATIQUE**

Projet

PROCESSUS GAUSSIENS POUR L'OPTIMISATION BAYÉSIENNE

Participants :

MAHAMOUD ABDILLAH OMR

MOHAMED ALI ABDOULKADER

KOUAME YAO FRANCK

MOUDINE ARMEL BOURI

LAGRE GABBA BERTRAND

JUIN 2026

Abstract

L’optimisation bayésienne est une approche efficace pour optimiser des fonctions coûteuses à évaluer, largement utilisée en apprentissage automatique, en ingénierie et en conception expérimentale. Son principe repose sur l’utilisation des processus gaussiens (Gaussian Processes, GP) comme modèles probabilistes permettant de prédire les valeurs d’une fonction inconnue tout en quantifiant l’incertitude associée.

Ce projet étudie les aspects théoriques, méthodologiques et pratiques de l’optimisation bayésienne basée sur les processus gaussiens. La partie méthodologique consiste à dériver la log-vraisemblance marginale utilisée pour l’estimation des hyperparamètres du noyau et à calculer les gradients nécessaires à leur optimisation. La partie computationnelle implémente la régression GP à l’aide de la décomposition de Cholesky, l’algorithme d’optimisation L-BFGS ainsi que les fonctions d’acquisition Expected Improvement (EI), Probability of Improvement (PI) et Upper Confidence Bound (UCB).

La contribution théorique porte sur trois résultats fondamentaux. Premièrement, nous dérivons la distribution prédictive a posteriori des processus gaussiens et obtenons les expressions analytiques de la moyenne et de la variance prédictives. Deuxièmement, nous démontrons l’équivalence entre la régression par processus gaussiens et les splines de lissage à travers le théorème de Kimeldorf–Wahba. Troisièmement, nous établissons la borne de regret de l’algorithme GP-UCB et montrons que le regret cumulé croît de manière sous-linéaire, garantissant la convergence vers l’optimum global.

Enfin, les méthodes développées sont appliquées à l’optimisation de la fonction de Rosenbrock en dimension 10 avec un budget de 200 évaluations. Les résultats obtenus confirment l’intérêt de l’optimisation bayésienne par rapport à une recherche aléatoire.

Introduction

De nombreux problèmes d’optimisation rencontrés en apprentissage automatique, en ingénierie et en recherche scientifique impliquent des fonctions dont l’évaluation est coûteuse en temps ou en ressources. Dans ce type de situation, chaque évaluation peut nécessiter beaucoup de temps, de calcul ou de ressources expérimentales. Les méthodes classiques d’optimisation deviennent alors peu efficaces car elles requièrent un grand nombre d’évaluations avant d’atteindre une solution satisfaisante.

L’optimisation bayésienne est une approche spécialement conçue pour résoudre ce problème. Elle consiste à construire un modèle probabiliste de la fonction inconnue à partir des observations déjà disponibles. Ce modèle permet ensuite de sélectionner intelligemment les

points les plus prometteurs à explorer. Parmi les modèles probabilistes existants, les processus gaussiens occupent une place centrale grâce à leur capacité à fournir simultanément une prédiction et une mesure de l'incertitude associée.

L'objectif de ce projet est d'étudier les fondements théoriques et algorithmiques de l'optimisation bayésienne basée sur les processus gaussiens. Nous analysons notamment la distribution prédictive a posteriori des GP, l'optimisation des hyperparamètres, l'équivalence entre les processus gaussiens et les splines de lissage, ainsi que les garanties théoriques de convergence de l'algorithme GP-UCB.

Pour la partie expérimentale, nous considérons la fonction de Rosenbrock en dimension 10, qui constitue un problème de référence classique en optimisation. Les observations sont modélisées par un ensemble de couples entrée-sortie supposées suivre un modèle bruité gaussien. L'étude est réalisée avec un budget de 200 évaluations de la fonction. Enfin, les performances de l'optimisation bayésienne utilisant les processus gaussiens et la fonction d'acquisition Expected Improvement sont comparées à celles d'une recherche aléatoire afin d'évaluer l'efficacité de l'approche proposée.

Théorie

Preuves théoriques

Démonstration du postérieur des processus gaussiens

L'objectif de cette section est de démontrer que, sous les hypothèses d'un processus gaussien et d'un bruit additif gaussien, la valeur de la fonction inconnue en un nouveau point x^* suit une loi normale conditionnelle dont la moyenne et la variance peuvent être obtenues analytiquement. Cette propriété constitue le fondement théorique de la régression par processus gaussiens et de l'optimisation bayésienne.

Hypothèses

Soit

$$f : \mathcal{X} \rightarrow \mathbb{R}$$

une fonction inconnue.

Hypothèse A1 : prior gaussien. On suppose que

$$f \sim \mathcal{GP}(m(x), k(x, x')).$$

Autrement dit, pour tout ensemble fini de points

$$X = (x_1, \dots, x_n),$$

le vecteur

$$f(X) = (f(x_1), \dots, f(x_n))$$

suit une loi normale multivariée. Dans toute cette démonstration, on suppose

$$m(x) = 0,$$

ce qui simplifie les calculs sans perte de généralité.

Hypothèse A2 : observations bruitées. Les données d'entraînement sont

$$\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n, \quad y_i = f(x_i) + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2), \quad \varepsilon_i \perp f.$$

Le bruit est donc indépendant du processus gaussien.

Hypothèse A3 : noyau positif défini. Le noyau $k(x, x')$ est symétrique et positif défini :

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j k(x_i, x_j) \geq 0.$$

Cette propriété garantit que toute matrice de covariance construite à partir de k est positive semi-définie.

Définitions

On définit la matrice de covariance

$$K = [k(x_i, x_j)]_{i,j=1}^n.$$

Pour un nouveau point x^* ,

$$k(X, x^*) = \begin{pmatrix} k(x_1, x^*) \\ \vdots \\ k(x_n, x^*) \end{pmatrix}, \quad k(x^*, X) = k(X, x^*)^\top,$$

et $k(x^*, x^*)$ désigne la variance a priori au point testé. Notre objectif est de déterminer

$$f(x^*) \mid \mathcal{D}_n.$$

Lemme 1 : gaussianité des observations

Énoncé. Le vecteur $f(X)$ vérifie

$$\boxed{f(X) \sim \mathcal{N}(0, K).}$$

Preuve. Par définition d'un processus gaussien,

$$\mathbb{E}[f(x_i)] = 0, \quad \text{Cov}(f(x_i), f(x_j)) = k(x_i, x_j).$$

En regroupant ces covariances dans une matrice,

$$K = [k(x_i, x_j)]_{i,j=1}^n, \quad \text{d'où} \quad f(X) \sim \mathcal{N}(0, K).$$

Lemme 2 : ajout du bruit gaussien

Énoncé. Le vecteur $y = f(X) + \varepsilon$ suit

$$y \sim \mathcal{N}(0, K + \sigma^2 I).$$

Preuve. Comme

$$\mathbb{E}[f(X)] = 0, \quad \mathbb{E}[\varepsilon] = 0, \quad \text{on obtient} \quad \mathbb{E}[y] = 0.$$

Par indépendance,

$$\text{Cov}(f, \varepsilon) = 0, \quad \text{donc} \quad \text{Cov}(y) = K + \sigma^2 I,$$

et par conséquent

$$y \sim \mathcal{N}(0, K + \sigma^2 I).$$

Lemme 3 : loi jointe

Le vecteur $\begin{pmatrix} y \\ f(x^*) \end{pmatrix}$ est gaussien :

$$\begin{pmatrix} y \\ f(x^*) \end{pmatrix} \sim \mathcal{N}\left(0, \begin{pmatrix} K + \sigma^2 I & k(X, x^*) \\ k(x^*, X) & k(x^*, x^*) \end{pmatrix}\right).$$

En effet,

$$\text{Cov}(y, f(x^*)) = \text{Cov}(f(X), f(x^*)) = k(X, x^*).$$

Théorème : distribution prédictive a posteriori

Sous les hypothèses précédentes,

$$f(x^*) \mid \mathcal{D}_n \sim \mathcal{N}(\mu_n(x^*), \sigma_n^2(x^*)),$$

avec

$$\mu_n(x^*) = k(x^*, X) [K + \sigma^2 I]^{-1} y,$$

$$\sigma_n^2(x^*) = k(x^*, x^*) - k(x^*, X) [K + \sigma^2 I]^{-1} k(X, x^*).$$

Preuve. Considérons

$$Z = \begin{pmatrix} A \\ B \end{pmatrix} \sim \mathcal{N}\left(0, \begin{pmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{pmatrix}\right).$$

Alors

$$B \mid A \sim \mathcal{N}(\Sigma_{BA}\Sigma_{AA}^{-1}A, \Sigma_{BB} - \Sigma_{BA}\Sigma_{AA}^{-1}\Sigma_{AB}).$$

Dans notre cas,

$$A = y, \quad B = f(x^*),$$

$$\Sigma_{AA} = K + \sigma^2 I, \quad \Sigma_{AB} = k(X, x^*), \quad \Sigma_{BA} = k(x^*, X), \quad \Sigma_{BB} = k(x^*, x^*).$$

En substituant ces blocs dans la formule générale,

$$\mu_n(x^*) = k(x^*, X) [K + \sigma^2 I]^{-1} y,$$

$$\sigma_n^2(x^*) = k(x^*, x^*) - k(x^*, X) [K + \sigma^2 I]^{-1} k(X, x^*).$$

La démonstration est ainsi complète.

Interprétation

La moyenne prédictive $\mu_n(x^*)$ fournit la meilleure estimation de la fonction inconnue au point considéré, tandis que la variance prédictive $\sigma_n^2(x^*)$ mesure explicitement l'incertitude associée à cette estimation. Lorsque x^* est proche des données d'entraînement, cette variance diminue fortement ; à l'inverse, lorsqu'il est éloigné des observations, on retrouve progressivement la variance a priori $k(x^*, x^*)$. Cette capacité à fournir simultanément une prédiction et une mesure d'incertitude explique l'utilisation des processus gaussiens dans les fonctions d'acquisition EI, PI et GP-UCB en optimisation bayésienne.

Conclusion de la démonstration du postérieur

La démonstration montre que, sous les hypothèses d'un prior gaussien et d'un bruit additif gaussien, la distribution conditionnelle de la fonction inconnue reste une loi normale dont la moyenne et la variance se calculent analytiquement. Cette propriété constitue le fondement mathématique de la régression par processus gaussiens et permet d'obtenir simultanément une prédiction et une mesure explicite de l'incertitude. C'est ce qui rend les processus gaussiens particulièrement adaptés aux méthodes d'optimisation bayésienne telles que EI, PI et GP-UCB.

Théorème de Kimeldorf–Wahba : équivalence entre processus gaussiens et splines de lissage

Objectif

L’objectif de cette section est de démontrer que la régression par processus gaussiens et les splines de lissage conduisent exactement au même estimateur. Plus précisément, nous montrons que le maximum a posteriori (MAP) obtenu sous un modèle de processus gaussien coïncide avec la solution du problème variationnel introduit par Kimeldorf et Wahba (1970). Cette équivalence établit un lien fondamental entre les méthodes probabilistes bayésiennes et les méthodes déterministes de régularisation.

Hypothèses

Considérons un ensemble d’observations

$$\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n, \quad y_i = f(x_i) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2),$$

les variables $\varepsilon_1, \dots, \varepsilon_n$ étant indépendantes. La fonction inconnue

$$f : \mathcal{X} \rightarrow \mathbb{R}$$

appartient à un espace de Hilbert à noyau reproduisant (RKHS) $\mathcal{H}_k$, associé à un noyau positif défini $k(x, x')$.

Définition du problème des splines de lissage

Une spline de lissage est définie comme la solution du problème d’optimisation

$$\hat{f} = \arg \min_{f \in \mathcal{H}_k} \left\{ \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}_k}^2 \right\}.$$

Le premier terme mesure l’erreur d’ajustement aux données tandis que le second pénalise la complexité de la fonction. Le paramètre

$$\lambda > 0$$

contrôle le compromis entre fidélité aux observations et régularité.

Prior gaussien sur les fonctions

Supposons maintenant que

$$f \sim \mathcal{GP}(0, k).$$

Dans un espace RKHS, le prior gaussien induit une densité proportionnelle à

$$p(f) \propto \exp\left(-\frac{1}{2}\|f\|_{\mathcal{H}_k}^2\right).$$

Les fonctions possédant une grande norme dans le RKHS sont donc moins probables que les fonctions plus régulières.

Vraisemblance des observations

Sous l'hypothèse du bruit gaussien,

$$p(y \mid f) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - f(x_i))^2}{2\sigma^2}\right).$$

En regroupant les termes indépendants de f ,

$$p(y \mid f) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f(x_i))^2\right).$$

Théorème de Kimeldorf–Wahba

Énoncé. Sous les hypothèses précédentes,

$$f_{\text{MAP}} = \arg \max_f p(f \mid y)$$

est exactement la solution du problème de spline

$$f_{\text{MAP}} = \arg \min_f \left[\sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}_k}^2 \right], \quad \lambda = \sigma^2.$$

Autrement dit,

Estimateur MAP = Spline de lissage.

Preuve détaillée

Étape 1 : théorème de Bayes. Par définition,

$$p(f \mid y) = \frac{p(y \mid f) p(f)}{p(y)}.$$

Comme $p(y)$ ne dépend pas de f ,

$$f_{\text{MAP}} = \arg \max_f p(y \mid f) p(f).$$

Étape 2 : passage au logarithme. Le logarithme étant strictement croissant,

$$f_{\text{MAP}} = \arg \max_f [\log p(y \mid f) + \log p(f)].$$

Étape 3 : développement de la vraisemblance.

$$\log p(y \mid f) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f(x_i))^2 + C_1,$$

où C_1 est une constante indépendante de f .

Étape 4 : développement du prior.

$$\log p(f) = -\frac{1}{2} \|f\|_{\mathcal{H}_k}^2 + C_2,$$

où C_2 est également indépendante de f .

Étape 5 : fonction objectif. En additionnant les deux expressions,

$$\log p(y \mid f) + \log p(f) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f(x_i))^2 - \frac{1}{2} \|f\|_{\mathcal{H}_k}^2 + C.$$

Maximiser cette quantité revient à minimiser son opposé :

$$f_{\text{MAP}} = \arg \min_f \left[\frac{1}{\sigma^2} \sum_{i=1}^n (y_i - f(x_i))^2 + \|f\|_{\mathcal{H}_k}^2 \right].$$

En multipliant toute l'expression par σ^2 ,

$$f_{\text{MAP}} = \arg \min_f \left[\sum_{i=1}^n (y_i - f(x_i))^2 + \sigma^2 \|f\|_{\mathcal{H}_k}^2 \right].$$

En posant

$$\lambda = \sigma^2,$$

on retrouve exactement le problème des splines de lissage. La démonstration est donc achevée.

Corollaire : théorème du représentant

Le théorème du représentant affirme que toute solution optimale appartient au sous-espace engendré par les noyaux évalués aux données :

$$f(x) = \sum_{i=1}^n \alpha_i k(x_i, x).$$

La recherche d'une fonction infinie-dimensionnelle est ainsi ramenée à l'estimation des coefficients $\alpha_1, \dots, \alpha_n$. En substituant cette représentation dans le problème précédent,

$$(K + \lambda I) \alpha = y, \quad \text{d'où} \quad \alpha = (K + \lambda I)^{-1} y.$$

Par conséquent,

$$f(x) = k(x, X) (K + \lambda I)^{-1} y.$$

Cette expression est exactement la moyenne prédictive obtenue en régression par processus gaussien.

Interprétation

Le théorème de Kimeldorf–Wahba montre que les splines de lissage et les processus gaussiens ne constituent pas deux approches distinctes, mais deux formulations mathématiques d'un même problème. L'approche spline est déterministe et repose sur une minimisation variationnelle, tandis que l'approche GP est probabiliste et fondée sur l'inférence bayésienne. Malgré leurs interprétations différentes, elles conduisent exactement au même estimateur. Cette équivalence explique pourquoi les noyaux jouent simultanément le rôle de fonctions de covariance dans les processus gaussiens et de fonctions de reproduction dans les espaces

RKHS.

Conclusion

La démonstration établit rigoureusement que le maximum a posteriori d'un processus gaussien est identique à la solution du problème de spline de lissage proposé par Kimeldorf et Wahba, reliant directement l'inférence bayésienne à la régularisation variationnelle et justifiant l'utilisation des processus gaussiens comme généralisation probabiliste des splines.

Borne de regret de GP-UCB

Objectif

L'objectif est de démontrer que l'algorithme Gaussian Process Upper Confidence Bound (GP-UCB) possède un regret cumulatif sous-linéaire, c'est-à-dire

$$R_N = \sum_{t=1}^N (f(x^*) - f(x_t)) = O^*(\sqrt{N \gamma_N}),$$

où x^* est l'optimum global de la fonction, x_t le point choisi à l'itération t et γ_N le gain maximal d'information. Cette propriété garantit que l'algorithme converge progressivement vers l'optimum.

Hypothèses

Hypothèse U1 : processus gaussien.

$$f \sim \mathcal{GP}(0, k),$$

où le noyau k est continu et positif défini, avec $k(x, x) \leq 1$.

Hypothèse U2 : bruit gaussien.

$$y_t = f(x_t) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2),$$

les variables étant indépendantes.

Hypothèse U3 : domaine compact.

$$\mathcal{X} \subset \mathbb{R}^d \text{ compact},$$

ce qui garantit l'existence d'un optimum global.

Convention de minimisation/maximisation

On présente GP-UCB dans la convention standard de *maximisation*. À chaque itération, GP-UCB choisit

$$x_t = \arg \max_{x \in \mathcal{X}} [\mu_{t-1}(x) + \sqrt{\beta_t} \sigma_{t-1}(x)],$$

où $\mu_{t-1}(x)$ est la moyenne prédictive, $\sigma_{t-1}(x)$ l'écart-type prédictif et $\beta_t > 0$ règle le compromis exploration/exploitation. La quantité $\mu_{t-1}(x) + \sqrt{\beta_t} \sigma_{t-1}(x)$ est appelée borne supérieure de confiance. *Pour l'application à Rosenbrock (minimisation), on utilise la forme inférieure équivalente*

$$\text{LCB}(x) = \mu_{t-1}(x) - \sqrt{\beta_t} \sigma_{t-1}(x),$$

que l'on minimise : minimiser f avec LCB équivaut à maximiser $-f$ avec UCB, et l'analyse de regret est identique.

Définition du regret

Le regret instantané est

$$r_t = f(x^*) - f(x_t),$$

et le regret cumulé est

$$R_N = \sum_{t=1}^N r_t.$$

L'objectif est de montrer que

$$\frac{R_N}{N} \longrightarrow 0.$$

Lemme 1 : intervalle de confiance (avec union bound)

Énoncé. Soit $\delta \in (0, 1)$ et

$$\beta_t = 2 \log\left(\frac{|\mathcal{X}| t^2 \pi^2}{6\delta}\right).$$

Avec probabilité au moins $1 - \delta$,

$$\boxed{|f(x) - \mu_{t-1}(x)| \leq \sqrt{\beta_t} \sigma_{t-1}(x) \quad \forall x \in \mathcal{X}, \forall t \geq 1.}$$

Preuve. Le postérieur GP fournit

$$f(x) \mid \mathcal{D}_{t-1} \sim \mathcal{N}(\mu_{t-1}(x), \sigma_{t-1}^2(x)), \quad Z = \frac{f(x) - \mu_{t-1}(x)}{\sigma_{t-1}(x)} \sim \mathcal{N}(0, 1).$$

La queue gaussienne donne

$$\Pr(|Z| \geq c) \leq e^{-c^2/2}.$$

En choisissant $c = \sqrt{\beta_t}$,

$$\Pr(|Z| \geq \sqrt{\beta_t}) \leq e^{-\beta_t/2} = \frac{6\delta}{|\mathcal{X}| t^2 \pi^2}.$$

Argument d'union bound (étape ajoutée pour justifier le « pour tout x et tout t »). En sommant sur les $|\mathcal{X}|$ points du domaine et sur $t \geq 1$, et puisque $\sum_{t \geq 1} t^{-2} = \pi^2/6$,

$$\sum_{t \geq 1} \sum_{x \in \mathcal{X}} \frac{6\delta}{|\mathcal{X}| t^2 \pi^2} = \sum_{t \geq 1} \frac{6\delta}{t^2 \pi^2} = \delta.$$

L'inégalité vaut donc simultanément pour tout x et tout t avec probabilité au moins $1 - \delta$.

Lemme 2 : majoration du regret instantané

Comme GP-UCB maximise $\mu_{t-1}(x) + \sqrt{\beta_t} \sigma_{t-1}(x)$,

$$\mu_{t-1}(x_t) + \sqrt{\beta_t} \sigma_{t-1}(x_t) \geq \mu_{t-1}(x^*) + \sqrt{\beta_t} \sigma_{t-1}(x^*).$$

Par le Lemme 1,

$$f(x^*) \leq \mu_{t-1}(x^*) + \sqrt{\beta_t} \sigma_{t-1}(x^*), \quad f(x_t) \geq \mu_{t-1}(x_t) - \sqrt{\beta_t} \sigma_{t-1}(x_t).$$

En combinant ces relations,

$$\boxed{r_t \leq 2\sqrt{\beta_t} \sigma_{t-1}(x_t).}$$

Lemme 3 : somme des variances

Le gain maximal d'information est

$$\gamma_N = \max_{A: |A|=N} I(y_A; f), \quad I(y_A; f) = \frac{1}{2} \log |I + \sigma^{-2} K_A|.$$

L'identité de la chaîne donne

$$I(y_{1:N}; f) = \frac{1}{2} \sum_{t=1}^N \log(1 + \sigma^{-2} \sigma_{t-1}^2(x_t)),$$

et comme $s \leq \frac{\log(1+s)}{\log(1+\sigma^{-2})}$ pour $0 \leq s \leq \sigma^{-2}$,

$$\boxed{\sum_{t=1}^N \sigma_{t-1}^2(x_t) \leq C_1 \gamma_N, \quad C_1 = \frac{2}{\log(1 + \sigma^{-2})}.}$$

Théorème : borne de regret GP-UCB

À partir du Lemme 2,

$$R_N = \sum_{t=1}^N r_t \leq 2\sqrt{\beta_N} \sum_{t=1}^N \sigma_{t-1}(x_t).$$

En appliquant l'inégalité de Cauchy-Schwarz,

$$\sum_{t=1}^N \sigma_{t-1}(x_t) \leq \sqrt{N \sum_{t=1}^N \sigma_{t-1}^2(x_t)},$$

puis le Lemme 3,

$$R_N \leq 2\sqrt{\beta_N} \sqrt{N C_1 \gamma_N}.$$

Comme $\beta_N = O(\log N)$,

$$R_N = O^*(\sqrt{N \beta_N \gamma_N}) = O^*(\sqrt{N \gamma_N}),$$

le facteur logarithmique étant absorbé dans la notation O^* .

Dérivation de γ_N pour le noyau exponentiel quadratique

Considérons le noyau exponentiel quadratique

$$k(x, x') = \sigma_f^2 \exp\left(-\frac{\|x - x'\|^2}{2\ell^2}\right).$$

On borne

$$\gamma_N = \max_{|A|=N} \frac{1}{2} \log \det(I + \sigma^{-2} K_A)$$

via le spectre de l'opérateur de covariance associé. Pour le noyau SE, les valeurs propres décroissent presque géométriquement,

$$\lambda_s = O(B^{s^{1/d}}), \quad B < 1.$$

On majore le déterminant par la somme des logarithmes,

$$\log \det(I + \sigma^{-2} K_A) \leq \sum_{s \geq 1} \log(1 + \sigma^{-2} N \lambda_s),$$

puis on scinde la somme à un seuil s_* :

$$\underbrace{\sum_{s \leq s_*} \log(1 + \sigma^{-2} N \lambda_s)}_{= O(s_* \log N)} + \underbrace{\sum_{s > s_*} \sigma^{-2} N \lambda_s}_{= O(1) \text{ si } N \lambda_{s_*} = O(1)} .$$

La condition $N \lambda_{s_*} = O(1)$ impose, vu la décroissance en $B^{s^{1/d}}$,

$$s_* = O((\log N)^d),$$

d'où

$$\boxed{\gamma_N = O(s_* \log N) = O((\log N)^{d+1}).}$$

Corollaire

En remplaçant cette borne dans le résultat précédent,

$$R_N = O^*(\sqrt{N(\log N)^{d+1}}), \quad \text{donc} \quad \frac{R_N}{N} = O^*\left(\sqrt{\frac{(\log N)^{d+1}}{N}}\right) \rightarrow 0.$$

Le regret moyen converge vers zéro : GP-UCB est un algorithme *sans regret*. La fonction d'acquisition EI, utilisée dans nos expériences, bénéficie de garanties de convergence analogues (Bull, 2011), ce qui justifie son emploi pratique.

Interprétation

GP-UCB équilibre naturellement l'exploitation des régions prometteuses (via la moyenne $\mu(x)$) et l'exploration des régions incertaines (via la variance $\sigma(x)$). Le terme $\sqrt{\beta_t} \sigma(x)$ agit comme une prime d'exploration qui décroît à mesure que l'information s'accumule, garantissant un regret cumulé sous-linéaire et donc la convergence vers l'optimum global.

Conclusion générale de la théorie

Les trois démonstrations constituent les fondements théoriques de l'optimisation bayésienne par processus gaussiens. La première établit la forme analytique de la distribution prédictive a posteriori, qui permet d'estimer simultanément la valeur d'une fonction inconnue et l'incertitude associée. La deuxième met en évidence l'équivalence entre processus gaussiens et splines de lissage, reliant l'inférence bayésienne aux méthodes classiques de régularisation dans les RKHS. La troisième démontre que GP-UCB bénéficie d'une garantie de convergence via une borne de regret sous-linéaire. Pris ensemble, ces résultats montrent que les processus gaussiens fournissent à la fois un outil de modélisation probabiliste et un cadre mathématique rigoureux pour construire des algorithmes d'optimisation efficaces et théoriquement justifiés.

Méthodologie

Vraisemblance, gradients et acquisition

Log-vraisemblance marginale

On considère les observations $y = (y_1, \dots, y_n)^\top$. Sous le modèle de régression par processus gaussien,

$$y \sim \mathcal{N}(0, K_\theta + \sigma^2 I), \quad K_y = K_\theta + \sigma^2 I.$$

La densité gaussienne multivariée donne

$$p(y \mid X, \theta) = \frac{1}{(2\pi)^{n/2} |K_y|^{1/2}} \exp\left(-\frac{1}{2} y^\top K_y^{-1} y\right).$$

En prenant le logarithme, on obtient la log-vraisemblance marginale :

$$\log p(y \mid X, \theta) = -\frac{1}{2} y^\top (K_\theta + \sigma^2 I)^{-1} y - \frac{1}{2} \log |K_\theta + \sigma^2 I| - \frac{n}{2} \log(2\pi).$$

Optimiser les hyperparamètres revient à maximiser cette quantité, ou de manière équivalente à minimiser son opposée.

Gradients par rapport aux hyperparamètres

On pose $\alpha = K_y^{-1} y$. À l'aide des identités matricielles

$$\frac{\partial K_y^{-1}}{\partial \theta_j} = -K_y^{-1} \frac{\partial K_y}{\partial \theta_j} K_y^{-1}, \quad \frac{\partial}{\partial \theta_j} \log |K_y| = \text{Tr}\left(K_y^{-1} \frac{\partial K_y}{\partial \theta_j}\right),$$

on obtient

$$\frac{\partial \mathcal{L}}{\partial \theta_j} = \frac{1}{2} \alpha^\top \frac{\partial K_y}{\partial \theta_j} \alpha - \frac{1}{2} \text{Tr}\left(K_y^{-1} \frac{\partial K_y}{\partial \theta_j}\right),$$

soit, sous forme compacte,

$$\frac{\partial \mathcal{L}}{\partial \theta_j} = \frac{1}{2} \text{Tr}\left[(\alpha \alpha^\top - K_y^{-1}) \frac{\partial K_y}{\partial \theta_j}\right].$$

Cette formule est celle utilisée dans l'optimisation L-BFGS des hyperparamètres.

Cas du noyau exponentiel quadratique

Le noyau utilisé dans les expériences est

$$k_\theta(x, x') = \sigma_f^2 \exp\left(-\frac{\|x - x'\|^2}{2\ell^2}\right),$$

où ℓ est la longueur d'échelle et σ_f^2 la variance du signal. En posant $r^2 = \|x - x'\|^2$, les dérivées utiles sont

$$\frac{\partial k_\theta(x, x')}{\partial \sigma_f^2} = \exp\left(-\frac{r^2}{2\ell^2}\right), \quad \frac{\partial k_\theta(x, x')}{\partial \ell} = k_\theta(x, x') \frac{r^2}{\ell^3},$$

et, pour la variance du bruit,

$$\frac{\partial K_y}{\partial \sigma^2} = I.$$

Fonctions d'acquisition (et dérivation de l'EI)

Une fois le modèle GP ajusté, l'optimisation bayésienne choisit le prochain point à partir de $\mu_n(x)$ et $\sigma_n(x)$. Pour une minimisation, on définit l'amélioration $I(x) = \max\{f_{\text{best}} - \xi - f(x), 0\}$, dont l'Expected Improvement est l'espérance a posteriori. En écrivant $f(x) = \mu_n(x) + \sigma_n(x)u$ avec $u \sim \mathcal{N}(0, 1)$, l'amélioration est positive si et seulement si $u < z$, et

$$\text{EI}(x) = (f_{\text{best}} - \mu_n(x) - \xi) \Phi(z) - \sigma_n(x) \int_{-\infty}^z u \phi(u) du.$$

Comme $\int_{-\infty}^z u \phi(u) du = -\phi(z)$, on obtient la forme close

$$\text{EI}(x) = (f_{\text{best}} - \mu_n(x) - \xi) \Phi(z) + \sigma_n(x) \phi(z), \quad z = \frac{f_{\text{best}} - \mu_n(x) - \xi}{\sigma_n(x)}.$$

La Probability of Improvement et la borne de confiance sont

$$\text{PI}(x) = \Phi\left(\frac{f_{\text{best}} - \mu_n(x) - \xi}{\sigma_n(x)}\right), \quad \text{UCB}(x) = \mu_n(x) + \kappa \sigma_n(x), \quad \text{LCB}(x) = \mu_n(x) - \kappa \sigma_n(x).$$

Ainsi, UCB est utilisée en maximisation et LCB en minimisation (cas de Rosenbrock).

Algorithme d'optimisation bayésienne

Algorithm 1 Optimisation bayésienne avec processus gaussien

```
1: Choisir quelques points initiaux et observer leurs valeurs.
2: for  $t = 1$  to  $N$  do
3:   Construire  $K_\theta$  à partir du noyau exponentiel quadratique.
4:   Former  $K_y = K_\theta + \sigma^2 I$ .
5:   Calculer la décomposition de Cholesky de  $K_y$ .
6:   Calculer  $\mu_{t-1}(x)$  et  $\sigma_{t-1}^2(x)$ .
7:   Optimiser les hyperparamètres par L-BFGS si nécessaire.
8:   Calculer EI, PI ou UCB/LCB sur les candidats.
9:   Sélectionner le prochain point  $x_t$ .
10:  Évaluer  $y_t = f(x_t)$ .
11:  Mettre à jour  $\mathcal{D}_t = \mathcal{D}_{t-1} \cup \{(x_t, y_t)\}$ .
12: end for
13: return la meilleure valeur observée.
```

Calcul et implémentation

Cholesky, L-BFGS et stabilité numérique

Régression GP avec décomposition de Cholesky

Les formules théoriques font intervenir l'inverse de $K + \sigma^2 I$. En pratique, l'inverse explicite n'est pas calculé. On utilise la décomposition de Cholesky

$$K_y = LL^\top,$$

puis on résout

$$Lv = y, \quad L^\top \alpha = v \quad \implies \quad \alpha = K_y^{-1} y.$$

La moyenne postérieure devient

$$\mu_n(x^*) = k(x^*, X) \alpha,$$

et la variance postérieure

$$\sigma_n^2(x^*) = k(x^*, x^*) - w^\top w, \quad w = L^{-1} k(X, x^*).$$

Cette approche est stable pour $n \leq 500$ car elle évite l'inversion directe. Un petit terme de stabilisation peut être ajouté :

$$K_y = K + \sigma^2 I + \tau I, \quad \tau > 0.$$

Extrait de code principal

```
Ky    = K + (noise_variance + jitter) * np.eye(n)
L      = np.linalg.cholesky(Ky)
alpha = np.linalg.solve(L.T, np.linalg.solve(L, y))
mu     = K_star.T @ alpha
w      = np.linalg.solve(L, K_star)
var    = K_ss - np.sum(w * w, axis=0)
```

L'implémentation calcule la moyenne et la variance postérieures sans inversion explicite de la matrice de covariance.

Analyse de stabilité numérique

Le terme de bruit $\sigma^2 I$ (complété par un jitter $\tau = 10^{-8}$) borne inférieurement les valeurs propres de la matrice de covariance. La figure 1 montre que le conditionnement de K seule

atteint $\approx 8 \times 10^7$ pour des points fortement corrélés, alors que celui de $K + \sigma^2 I$ reste autour de 10^5 , soit une amélioration d'environ deux ordres de grandeur. L'erreur relative de reconstruction de Cholesky,

$$\frac{\|LL^\top - K_y\|}{\|K_y\|},$$

reste inférieure à 10^{-10} sur toute la plage testée.




Figure 1: Analyse de stabilité numérique. Gauche : conditionnement de K sans le terme de bruit (rouge) et de $K + \sigma^2 I$ (bleu). Droite : erreur relative de la factorisation de Cholesky en fonction de n .

Vérification du gradient. Le gradient analytique de la log-vraisemblance a été comparé aux différences finies centrées (données aléatoires, $n = 12$, $d = 3$). L'écart absolu maximal est

$$\max_j |\partial_j^{\text{analytique}} - \partial_j^{\text{numérique}}| = 1,7 \times 10^{-8},$$

ce qui confirme l'exactitude de l'implémentation et la fiabilité de l'optimisation L-BFGS.

L-BFGS pour l'optimisation des hyperparamètres

L-BFGS minimise l'opposé de la log-vraisemblance marginale en utilisant le gradient analytique. À chaque itération, il stocke les différences

$$s_k = \theta_{k+1} - \theta_k, \quad y_k = \nabla f(\theta_{k+1}) - \nabla f(\theta_k),$$

puis applique la récursion à deux boucles pour approximer l'inverse de la hessienne, avec mise à l'échelle initiale

$$\gamma_k = \frac{s_k^\top y_k}{y_k^\top y_k},$$

une recherche linéaire d'Armijo et la garde de courbure $s_k^\top y_k > 0$. Cela permet d'optimiser les hyperparamètres sans bibliothèque de haut niveau.

Complexité et dépôt

La construction de K coûte $O(n^2)$, la décomposition de Cholesky $O(n^3)$, et la prédiction sur m candidats $O(n^2m)$. Pour $n \leq 500$, ce coût reste acceptable. Le script Python complet est hébergé sur GitHub sous le nom `gaussian_process_bayesian_optimization.py` ; le lien est communiqué avec la soumission finale.

Application et résultats

Rosenbrock en dimension 10

Fonction de Rosenbrock en dimension 10

La fonction boîte noire choisie est

$$f(x) = \sum_{i=1}^9 [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2],$$

de minimum global

$$x^* = (1, \dots, 1), \quad f(x^*) = 0,$$

sur le domaine $[-2, 2]^{10}$, avec un budget de $n = 200$ évaluations.

Protocole expérimental

Deux méthodes sont comparées à budget égal :

- **GP-EI** : optimisation bayésienne avec processus gaussien et Expected Improvement ;
- **Random Search** : recherche aléatoire uniforme dans le domaine.

À chaque itération, on mesure

$$\text{best}_t = \min_{1 \leq i \leq t} f(x_i).$$

Métriques et tests statistiques

Soit $B_s^{(m)}$ la meilleure valeur trouvée par la méthode m à la répétition s (on utilise $S = 5$ répétitions indépendantes). On rapporte la moyenne

$$\overline{B}^{(m)} = \frac{1}{S} \sum_{s=1}^S B_s^{(m)},$$

avec un intervalle de confiance bootstrap à 95 % (10^4 ré-échantillonnages avec remise, quantiles 2,5 % et 97,5 %), et un test t apparié sur $D_s = B_s^{\text{EI}} - B_s^{\text{rand}}$,

$$t = \frac{\overline{D}}{s_D / \sqrt{S}}.$$

Remarque. La statistique de Diebold–Mariano figurant dans une version préliminaire a été retirée : appliquée à la courbe monotone du meilleur-jusqu’ici (fortement autocorrélée), son calcul n’était pas valide.

Résultats numériques

Méthode	Moyenne finale	Écart-type	IC bootstrap 95 %
GP-EI	71,93	20,93	[55,87 ; 87,99]
Random Search	544,67	252,20	[323,25 ; 693,39]

Le test t apparié donne

$$t = -4,33, \quad p = 0,012.$$

Interprétation. Avec cinq répétitions indépendantes, la différence entre GP-EI et la recherche aléatoire est **significative au seuil de 5 %**, et les deux intervalles de confiance bootstrap **ne se chevauchent pas** ([55,87 ; 87,99] contre [323,25 ; 693,39]). GP-EI surpasse donc significativement la recherche aléatoire sur ce problème, ce qui confirme l'apport de l'exploitation de l'historique des observations par le modèle GP.

Courbe de convergence




Figure 2: Convergence : meilleure valeur observée au fil des évaluations. GP-EI exploite l'historique des observations, contrairement à la recherche aléatoire. *Remplacer par votre figure réelle.*

Moyenne postérieure et variance postérieure

Comme Rosenbrock est en dimension 10, on visualise une coupe 1D : les autres dimensions sont fixées et l'on fait varier une seule coordonnée. La figure 3 montre la moyenne postérieure du GP et l'intervalle de confiance associé.




Figure 3: Coupe 1D : moyenne a posteriori et incertitude du GP (autres dimensions fixées).
Remplacer par votre figure réelle.

Discussion

Les formules de moyenne et de variance postérieures permettent de combiner prédiction et incertitude dans les fonctions d'acquisition. La log-vraisemblance marginale ajuste les hyperparamètres du noyau, tandis que la décomposition de Cholesky assure une résolution numérique stable. L'expérience sur Rosenbrock en dimension 10 illustre l'utilisation pratique de ces éléments. Les résultats montrent que GP-EI surpasse significativement la recherche aléatoire, en exploitant simultanément la prédiction moyenne et l'incertitude.

Limites. Le coût $O(n^3)$ de Cholesky rend le GP exact impraticable au-delà de $n \approx 10^3$; en grande dimension, l'optimisation de l'acquisition est difficile ; et la garantie de regret suppose un prior GP connu, hypothèse que Rosenbrock viole. *Robustesse statistique.* Les conclusions reposent sur cinq répétitions, qui suffisent ici à atteindre la significativité ($p = 0,012$) avec des intervalles de confiance disjoints ; un nombre encore plus grand de répétitions resserrerait davantage les intervalles. *Perspectives.* Noyaux de Matérn, déformation des entrées, BO par lots, et optimisation par régions de confiance (TuRBO) en grande dimension.

Tableau de contribution

Chaque membre a au moins deux contributions majeures distinctes. Tableau à valider honnêtement par le groupe pour refléter le travail réel.

Tâche / Section	Mahamoud	Mohamed Ali	Kouame F.	Moudine A.	Lagrenée
Théorie : postérieur GP & EI	X				
Théorie : Kimeldorf–Wahba / regret		X			
Méthodologie : algorithmes, complexité		X	X		
Calcul : code GP / Cholesky			X	X	
Calcul : L-BFGS, gradients, stabilité				X	X
Application : expériences, statistiques	X				X
Rédaction LaTeX	X	X	X	X	X
Présentation vidéo (prise de parole)	X	X	X	X	X

References

- [1] C. E. Rasmussen, C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.
- [2] G. Kimeldorf, G. Wahba. A correspondence between Bayesian estimation on stochastic processes and smoothing by splines. *Annals of Mathematical Statistics*, 41(2):495–502, 1970.
- [3] N. Srinivas, A. Krause, S. M. Kakade, M. Seeger. Gaussian process optimization in the bandit setting: no regret and experimental design. *ICML*, 2010.
- [4] D. R. Jones, M. Schonlau, W. J. Welch. Efficient global optimization of expensive black-box functions. *Journal of Global Optimization*, 13:455–492, 1998.
- [5] J. Mockus, V. Tiesis, A. Zilinskas. The application of Bayesian methods for seeking the extremum. *Towards Global Optimization*, 1978.
- [6] E. Brochu, V. M. Cora, N. de Freitas. A tutorial on Bayesian optimization of expensive cost functions. 2010.
- [7] B. Shahriari et al. Taking the human out of the loop: a review of Bayesian optimization. *Proceedings of the IEEE*, 104(1):148–175, 2016.
- [8] J. Snoek, H. Larochelle, R. P. Adams. Practical Bayesian optimization of machine learning algorithms. *NIPS*, 2012.
- [9] A. D. Bull. Convergence rates of efficient global optimization algorithms. *JMLR*, 12:2879–2904, 2011.
- [10] C. K. I. Williams, C. E. Rasmussen. Gaussian processes for regression. *NIPS*, 1996.
- [11] M. Seeger. Gaussian processes for machine learning. *International Journal of Neural Systems*, 14(2):69–106, 2004.
- [12] D. C. Liu, J. Nocedal. On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, 45:503–528, 1989.